

LAPORAN
ANALITIK DAN VISUALISASI DATA
ANALISIS PENJUALAN PARFUM PRIA DI MARKETPLACE EBAY
MENGGUNAKAN EXPLORATORY DATA ANALYSIS (EDA)



Disusun oleh:

Rizki Adrianur Saputra (2509116049)

Program Studi Sistem Informasi

Fakultas Teknik

Universitas Mulawarman

2026

KATA PENGANTAR

Puji syukur penulis panjatkan kehadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya laporan yang berjudul Analisis Penjualan Parfum Pria di Marketplace eBay Menggunakan Exploratory Data Analysis (EDA) dapat diselesaikan dengan baik. Laporan ini disusun sebagai salah satu tugas praktikum mata kuliah Analitik dan Visualisasi Data dengan fokus pada proses Data Understanding dan Exploratory Data Analysis (EDA) menggunakan bahasa pemrograman Python.

Penulis menyadari bahwa dalam penyusunan laporan ini masih terdapat kekurangan, baik dari segi penulisan maupun penyajian materi. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun demi perbaikan di masa yang akan datang. Semoga laporan ini dapat memberikan manfaat serta menambah wawasan pembaca mengenai proses analisis data, khususnya pada tahap eksplorasi data untuk memahami karakteristik dataset dan pola yang terdapat pada data. Akhir kata, penulis mengucapkan terima kasih kepada semua pihak yang telah membantu dalam penyusunan laporan ini.

Samarinda, 15 Maret 2026

Rizki Adrianur Saputra

DAFTAR ISI

DAFTAR ISI.....	2
DAFTAR GAMBAR.....	3
BAB I PENDAHULUAN.....	4
1.1 Latar Belakang	4
1.2 Tujuan Analisis	5
BAB II PEMBAHASAN.....	6
2.1 Business Understanding	6
2.1.1 Business Objective	6
2.1.2 Assess Situation	6
2.1.3 Analytic Goals.....	7
2.1.4 Project Plan	8
2.2 Data Understanding & EDA	9
2.2.1 Data Understanding.....	9
2.2.2 Eksplorasi Data (EDA)	26
BAB III PENUTUP	35
3.1 Kesimpulan	35
3.2 Saran.....	36

DAFTAR GAMBAR

Gambar 1 Hasil Perintah df.....	10
Gambar 2 Hasil Perintah df.info().....	10
Gambar 3 Hasil perintah df.describe()	12
Gambar 4 Perintah df.types.....	14
Gambar 5 Print(df['brand'].unique())	15
Gambar 6 Print(df['title'].unique())	16
Gambar 7 Print(df['type'].unique())	17
Gambar 8 Print(df['price'].unique()).....	18
Gambar 9 Print(df['availableText'].unique()).....	20
Gambar 10 Print(df['sold'].unique()).....	21
Gambar 11 Print(df['lastUpdated'].unique())	22
Gambar 12 Print(df['itemLocation'].unique())	22
Gambar 13 Missing Values.....	23
Gambar 14 Duplicated Values	24
Gambar 15 Outliers Values.....	25
Gambar 16 Visualisasi Comparison.....	27
Gambar 17 Visualisasi Composition.....	29
Gambar 18 Visualisasi Distribution 1	30
Gambar 19 Visualisasi Distribution 2	32
Gambar 20 Visualisasi Relationship	33

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan internet telah mendorong peningkatan aktivitas jual beli melalui platform marketplace. Salah satu marketplace yang dikenal secara global adalah eBay, yang menyediakan berbagai jenis produk dari berbagai negara, termasuk produk parfum pria. Banyaknya variasi merek, jenis parfum, harga produk, hingga lokasi penjual menyebabkan persaingan antar penjual menjadi semakin tinggi. Kondisi ini membuat penjual perlu memahami pola penjualan dan preferensi konsumen agar dapat menentukan strategi bisnis yang lebih tepat serta mampu bersaing di pasar digital yang terus berkembang.

Data penjualan parfum pria pada marketplace eBay menyimpan berbagai informasi penting seperti nama produk, merek parfum, jenis parfum, harga produk, jumlah stok yang tersedia, jumlah produk yang telah terjual, serta lokasi penjual. Informasi tersebut dapat dimanfaatkan untuk mengetahui produk yang paling diminati oleh konsumen maupun melihat pola penjualan yang terjadi pada marketplace. Namun, data yang diperoleh umumnya masih berupa data mentah sehingga perlu dilakukan proses pemeriksaan dan pembersihan data terlebih dahulu, seperti identifikasi missing values, inconsistent values, duplicated values, dan outliers agar data yang digunakan menjadi lebih bersih dan akurat.

Setelah data dapat dipersiapkan dengan baik dengan melakukan analisis menggunakan pendekatan Exploratory Data Analysis (EDA). EDA memungkinkan data dianalisis untuk memahami karakteristik, pola, serta permasalahan yang terdapat pada dataset sebelum dilakukan analisis lebih lanjut. Melalui proses ini, pengguna dapat melihat distribusi data, perbandingan penjualan antar merek, hubungan antar variabel, serta mendeteksi adanya missing values maupun outliers pada data. Selain itu, EDA juga membantu menyajikan informasi dalam bentuk grafik yang lebih mudah dipahami dibandingkan hanya melalui tabel atau angka. Dengan demikian, penerapan Exploratory Data Analysis (EDA) dapat membantu memahami kondisi data secara lebih jelas serta mendukung proses pengambilan keputusan berdasarkan hasil analisis data.

1.2 Tujuan Analisis

Berdasarkan permasalahan yang telah dijelaskan sebelumnya, tujuan dari analisis data ini adalah sebagai berikut:

1. Memahami karakteristik dataset penjualan parfum pria pada marketplace eBay melalui proses Data Understanding.
2. Mengidentifikasi permasalahan data seperti missing values, inconsistent values, duplicated values, dan outliers agar kualitas data lebih baik sebelum dianalisis.
3. Menganalisis distribusi penjualan produk parfum pria berdasarkan merek, jenis parfum, harga produk, dan jumlah produk terjual.
4. Mengetahui brand parfum dan jenis parfum yang memiliki tingkat penjualan tertinggi.
5. Menganalisis hubungan antara harga produk, jumlah stok yang tersedia, dan jumlah produk yang terjual.

BAB II

PEMBAHASAN

2.1 Business Understanding

Business Understanding merupakan tahap awal dalam proses analisis data yang bertujuan untuk memahami permasalahan bisnis, tujuan yang ingin dicapai, serta kebutuhan solusi dari sudut pandang bisnis. Pada tahap ini dilakukan identifikasi terhadap tujuan bisnis, penilaian situasi yang ada, penentuan tujuan analisis, serta penyusunan rencana proyek yang akan dilakukan dalam proses analisis data.

2.1.1 Business Objective

Dataset yang digunakan pada penelitian ini merupakan data penjualan parfum pria yang berasal dari marketplace eBay. Dataset tersebut berisi berbagai informasi produk, seperti nama parfum, merek, harga, jumlah stok yang tersedia, jumlah produk yang telah terjual, serta lokasi penjual. Data ini menggambarkan aktivitas pelanggan dalam melakukan transaksi parfum pada platform e-commerce dan dapat digunakan untuk melihat bagaimana produk dipasarkan serta diminati oleh konsumen.

Dalam dunia bisnis online, penjual sering menghadapi kesulitan dalam memahami faktor-faktor yang memengaruhi tingkat penjualan produk. Perbedaan harga antar produk, popularitas merek, serta ketersediaan stok dapat memberikan pengaruh yang berbeda terhadap keputusan pembelian konsumen. Tanpa analisis data yang tepat, penjual cenderung hanya mengandalkan perkiraan atau pengalaman pribadi dalam menentukan strategi penjualan. Oleh karena itu, analisis terhadap dataset ini dilakukan untuk memahami pola penjualan serta mengidentifikasi faktor-faktor yang berperan penting terhadap tinggi rendahnya penjualan parfum yang dijual pada platform e-commerce.

2.1.2 Assess Situation

Dataset yang digunakan pada penelitian ini memiliki 1000 baris data yang memuat beberapa informasi mengenai harga produk, jumlah stok yang tersedia, jumlah produk yang telah terjual, merek parfum, type parfum, waktu update serta lokasi penjual. Data ini sudah dapat digunakan sebagai bahan analisis awal. Namun, terdapat beberapa tantangan yang dihadapi oleh penjual, diantara lain:

1. Beberapa kolom masih memiliki data yang kosong atau *missing values*
2. format penulisan harga yang belum seragam
3. Variasi merek parfum yang beragam
4. Kemungkinan adanya outlier pada harga atau jumlah penjualan yang dapat mempengaruhi hasil analisis

Oleh sebab itu, tahap persiapan data menjadi langkah penting agar dataset berada dapat lebih bersih dan siap digunakan, sehingga hasil analisis yang diperoleh nantinya dapat lebih akurat dan dapat dipercaya.

2.1.3 Analytic Goals

Dari dataset yang telah diamati, kita dapat menentukan tujuan berupa:

1. Memahami faktor-faktor yang dapat memengaruhi tingkat penjualan parfum pria di marketplace.
2. Menganalisis hubungan antara harga produk, ketersediaan stok, serta merek parfum terhadap jumlah produk yang terjual.
3. Mengidentifikasi pola penjualan berdasarkan karakteristik produk yang tersedia pada dataset
4. Mengetahui kategori produk atau merek yang memiliki performa penjualan lebih baik dibandingkan produk lainnya.
5. Menganalisis pengaruh jenis parfum terhadap penjualan
6. Meneliti apakah lokasi penjual berpengaruh terhadap tingkat penjualan

Melalui proses analisis ini, diharapkan dapat memperlihatkan pola penjualan yang muncul dari data, termasuk produk mana yang memiliki performa penjualan lebih baik dibandingkan yang lain. Diharapkan hasil analisis nantinya dapat memberikan gambaran yang lebih jelas bagi penjual dalam menentukan strategi penetapan harga maupun pengelolaan produk, sehingga keputusan yang diambil tidak hanya berdasarkan perkiraan, tetapi juga didukung oleh data.

2.1.4 Project Plan

Rencana pengerjaan proyek analisis data ini akan dilakukan melalui beberapa tahapan berikut:

1. Business Understanding

Dataset yang digunakan merupakan data penjualan parfum pria dari marketplace eBay yang berisi informasi seperti harga, stok, jumlah terjual, merek, tipe parfum, dan lokasi penjual. Dalam bisnis e-commerce, penjual sering kesulitan menentukan strategi karena banyak faktor yang memengaruhi penjualan, seperti harga, popularitas merek, dan ketersediaan produk. Oleh karena itu, analisis ini dilakukan untuk memahami pola penjualan serta mengidentifikasi faktor yang paling berpengaruh terhadap tingkat penjualan.

2. Data Understanding

Tahap ini bertujuan untuk memahami kondisi awal dataset, meliputi:

- Identifikasi jumlah data dan tipe variabel
- Melihat distribusi harga, stok, dan jumlah terjual
- Mengetahui variasi merek dan tipe parfum
- Mengidentifikasi missing values
- Mendeteksi adanya outlier

Tahap ini penting untuk mengetahui kualitas data sebelum dilakukan pengolahan lebih lanjut.

3. Eksplorasi Data (EDA)

Tahap Exploratory Data Analysis (EDA) bertujuan untuk memahami karakteristik dan pola data pada dataset parfum e-commerce sebelum dilakukan analisis atau pemodelan lebih lanjut, meliputi:

- Identifikasi jumlah data dan tipe variabel pada dataset
- Melihat distribusi data seperti harga parfum, jumlah stok tersedia, dan jumlah produk terjual
- Mengetahui hubungan antar variabel, seperti hubungan harga dengan jumlah terjual
- Menganalisis variasi merek dan tipe parfum yang tersedia pada marketplace

- Mengidentifikasi missing values atau data yang kosong
- Mendeteksi adanya outlier pada data penjualan maupun harga
- Mengetahui persebaran data berdasarkan lokasi penjualan produk

Tahap EDA ini penting dilakukan untuk memahami kualitas data, menemukan pola atau anomali pada dataset, serta membantu menentukan langkah pengolahan dan analisis data yang tepat pada tahap selanjutnya.

2.2 Data Understanding & EDA

Data Understanding merupakan tahap awal dalam analisis data yang bertujuan untuk memahami struktur dan karakteristik dataset, seperti jenis data, jumlah data, serta informasi pada setiap variabel. Setelah itu dilakukan Exploratory Data Analysis (EDA) untuk melihat gambaran umum data dan mengidentifikasi permasalahan yang mungkin terdapat pada dataset, seperti tipe data yang tidak sesuai, inconsistent values, missing values, duplicated values, dan outliers. Tahapan yang dilakukan pada proses ini dijelaskan sebagai berikut:

2.2.1 Data Understanding

Dalam proses Data Understanding, diperlukan beberapa library Python untuk membantu membaca dan mengakses dataset yang akan dianalisis, yaitu:

```
import pandas as pd
from google.colab import drive
drive.mount('/content/drive')
```

Pada tahap ini digunakan *library Pandas* yang diimpor dengan perintah *import pandas as pd* untuk membaca dan mengolah dataset. Selain itu menggunakan perintah *from google.colab import drive* dan *drive.mount('/content/drive')* untuk menghubungkan Google Colab dengan penyimpanan Google Drive sehingga file dataset dapat diakses.

2.2.1.1 Memuat Dataset

```
File = '/content/drive/MyDrive/Praktikum/ebay_mens_perfume (1).csv'
df = pd.read_csv(file)
df =
```

Perintah `file = '/content/drive/MyDrive/Praktikum/ebay_mens_perfume (1).csv'` digunakan untuk menyimpan lokasi atau path file dataset. Perintah `df = pd.read_csv(file)` digunakan untuk membaca file CSV dan memuatnya ke dalam DataFrame, kemudian perintah `df` digunakan untuk menampilkan isi data yang telah berhasil dimuat.

df

	brand	title	type	price	priceWithCurrency	available	availableText	sold	lastUpdated	itemLocation
0	Dior	Christian Dior Sauvage Men's EDP 3.4 oz Fragra...	Eau de Parfum	84.99	US \$84.99/ea	10.0	More than 10 available / 116 sold	116.0	May 24, 2024 10:03:04 PDT	Allen Park, Michigan, United States
1	AS SHOW	A-v-entus Eau de Parfum 3.3 oz 100ML Milliesime...	Eau de Parfum	109.99	US \$109.99	8.0	8 available / 48 sold	48.0	May 23, 2024 23:07:49 PDT	Atlanta, Georgia, Canada
2	Unbranded	HOGO BOSS cologne For Men 3.4 oz	Eau de Toilette	100.00	US \$100.00	10.0	More than 10 available / 27 sold	27.0	May 22, 2024 21:55:43 PDT	Dearborn, Michigan, United States
3	Giorgio Armani	Acqua Di Gio by Giorgio Armani 6.7 Fl oz Eau D...	Eau de Toilette	44.99	US \$44.99/ea	2.0	2 available / 159 sold	159.0	May 24, 2024 03:30:43 PDT	Reinholds, Pennsylvania, United States
4	Lattafa	Lattafa Men's Hayaati Al Maleky EDP Spray 3.4 ...	Fragrances	16.91	US \$16.91	NaN	Limited quantity available / 156 sold	156.0	May 24, 2024 07:56:25 PDT	Brooklyn, New York, United States
...	...	...	...	...	...	...	...	...	...	...
995	GUESS	Guess 1981 by Guess cologne for men EDT 3.3 / ...	Eau de Toilette	20.28	US \$20.28/ea	45.0	45 available / 1,613 sold	1613.0	May 24, 2024 08:14:07 PDT	Dallas, Texas, United States
996	Armaf	Club de Nuit Intense by Armaf cologne for men ...	Eau de Toilette	30.58	US \$30.58	10.0	More than 10 available / 31 sold	31.0	May 23, 2024 06:39:30 PDT	United States
997	Paco Rabanne	Invictus by Paco Rabanne for Men EDT Spray 3.4...	Eau de Toilette	39.99	US \$39.99/ea	2.0	2 available / 305 sold	305.0	May 23, 2024 15:27:18 PDT	Jamaica, New York, United States
998	Lomani	Lomani EDT Cologne 3.4 oz Men - Authentic, Bra...	Eau de Toilette	9.99	US \$9.99/ea	2.0	2 available / 22 sold	22.0	May 20, 2024 13:20:54 PDT	Lincoln Park, Michigan, United States
999	Estee Lauder	Beyond Paradise by Estee Lauder for Men Cologn...	Cologne spray	17.49	US \$17.49/ea	10.0	More than 10 available / 24 sold	24.0	Feb 28, 2024 07:27:01 PST	Keyport, New Jersey, United States

1000 rows x 10 columns

Gambar 1 Hasil Perintah `df`

2.2.1.2.1 Informasi Dasar dan Lanjutan

`df.info()`

Pada tahap ini digunakan perintah `df.info()` untuk menampilkan ringkasan informasi dari dataset. Informasi yang ditampilkan meliputi jumlah baris data, jumlah kolom, nama setiap kolom, tipe data pada masing-masing kolom, serta jumlah data yang tidak kosong pada setiap kolom. Informasi ini membantu dalam memahami struktur dataset dan mengetahui apakah terdapat data yang kosong sebelum dilakukan proses analisis lebih lanjut.

`df.info()`

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   brand                 999 non-null    object
1   title                 1000 non-null   object
2   type                  997 non-null    object
3   price                 1000 non-null   float64
4   priceWithCurrency     1000 non-null   object
5   available             889 non-null    float64
6   availableText         997 non-null    object
7   sold                  994 non-null    float64
8   lastUpdated           947 non-null    object
9   itemLocation          1000 non-null   object
dtypes: float64(3), object(7)
memory usage: 78.3+ KB
```

Gambar 2 Hasil Perintah `df.info()`

Berdasarkan data di atas, dapat diketahui bahwa dataset ini memiliki 1000 baris dan 10 kolom. Dengan detail setiap kolomnya sebagai berikut:

1. brand: Jumlah baris: 999 Tipe data: object Deskripsi: Merek produk parfum
2. title: Jumlah baris: 1000 Tipe data: object Deskripsi: Nama atau judul produk parfum
3. type: Jumlah baris: 997 Tipe data: object Deskripsi: Jenis atau kategori parfum
4. price: Jumlah baris: 1000 Tipe data: float64 Deskripsi: Harga produk parfum
5. priceWithCurrency: Jumlah baris: 1000 Tipe data: object Deskripsi: Harga produk beserta mata uang
6. available: Jumlah baris: 889 Tipe data: float64 Deskripsi: Status ketersediaan stok produk
7. availableText: Jumlah baris: 997 Tipe data: object Deskripsi: Informasi teks mengenai ketersediaan produk
8. sold: Jumlah baris: 994 Tipe data: float64 Deskripsi: Jumlah produk yang telah terjual
9. lastUpdated: Jumlah baris: 947 Tipe data: object Deskripsi: Waktu terakhir data diperbarui
10. itemLocation: Jumlah baris: 1000 Tipe data: object Deskripsi: Lokasi penjual atau asal produk

2.2.1.2.2 Informasi Statistik Deskriptif

```
df.describe(include='all')
```

Perintah `df.describe(include='all')` digunakan untuk menampilkan ringkasan statistik dari seluruh kolom pada DataFrame, baik data numerik maupun non-numerik. Dengan menambahkan `include='all'`, fungsi ini dapat menampilkan informasi penting seperti jumlah data (count), jumlah nilai unik (unique), nilai yang paling sering muncul (top), frekuensinya (freq), serta statistik numerik seperti rata-rata (mean), nilai minimum (min), dan maksimum (max). Perintah ini membantu memberikan gambaran umum mengenai karakteristik dataset sebelum dilakukan analisis lebih lanjut.

```
df.describe(include='all')
```

... /usr/local/lib/python3.12/dist-packages/google/colab/dataframe_summarizer.py:88: FutureWarning: Parsed string "May 24, 2024 10:26:59 PDT" included an un-recognized timezone
cast_date_col = pd.to_datetime(column, errors="coerce")

	brand	title	type	price	priceWithCurrency	available	availableText	sold	lastUpdated	itemLocation
count	999	1000	997	1000.000000	1000	889.000000	997	994.000000	947	1000
unique	246	966	63	NaN	685	NaN	758	NaN	933	276
top	Giorgio Armani	YSL Yves Saint Laurent Y Eau de Perfume Spray ...	Eau de Toilette	NaN	US \$29.99/ea	NaN	More than 10 available / 16 sold	NaN	May 24, 2024 10:26:59 PDT	Dallas, Texas, United States
freq	60	4	444	NaN	21	NaN	8	NaN	4	126
mean	NaN	NaN	NaN	46.481200	NaN	20.046119	NaN	766.266600	NaN	NaN
std	NaN	NaN	NaN	35.527862	NaN	61.547985	NaN	3200.971733	NaN	NaN
min	NaN	NaN	NaN	3.000000	NaN	2.000000	NaN	1.000000	NaN	NaN
25%	NaN	NaN	NaN	22.990000	NaN	5.000000	NaN	14.000000	NaN	NaN
50%	NaN	NaN	NaN	35.710000	NaN	10.000000	NaN	49.500000	NaN	NaN
75%	NaN	NaN	NaN	59.000000	NaN	10.000000	NaN	320.500000	NaN	NaN
max	NaN	NaN	NaN	259.090000	NaN	842.000000	NaN	54052.000000	NaN	NaN

Gambar 3 Hasil perintah `df.describe()`

Berdasarkan informasi di atas, dapat diperoleh beberapa insight mengenai kondisi dan kelengkapan data pada dataset yang digunakan:

1. Count

berdasarkan data, total baris dataset adalah 1000 data. maka dapat disimpulkan:

- Brand hilang 1 data (1000 – 999)
- Type hilang 3 data (1000 – 997)
- Available hilang 111 data (1000 – 889)
- Availabletext hilang 3 data (1000 – 997)
- Sold hilang 6 data (1000 – 994)
- lastupdated hilang 53 data (1000 – 947)

kesimpulan: beberapa kolom masih mengandung missing values, terutama pada kolom available dan lastupdated, sedangkan kolom title, price, pricewithcurrency, dan itemlocation sudah lengkap (1000 data).

2. mean vs median

A. Kolom Price

- Mean = 46.48
- Median = 35.71

nilai rata-rata lebih besar dari median, menunjukkan adanya beberapa parfum dengan harga sangat tinggi yang menarik rata-rata ke atas (outlier).

B. Kolom Available

- Mean = 20.05
- Median = 10.00

rata-rata jauh lebih besar dari median, menunjukkan sebagian kecil produk memiliki stok sangat banyak dibandingkan dengan mayoritas produk lainnya.

C. Kolom Sold

- Mean = 766.27
- Median = 49.50

rata-rata jauh lebih besar dari median, menunjukkan adanya produk dengan penjualan sangat tinggi sehingga distribusi data tidak merata.

kesimpulan: secara keseluruhan distribusi data bersifat skewed right (condong ke kanan) terdapat beberapa nilai yang ekstrem sehingga memengaruhi nilai rata-rata pada seluruh variabel utama.

3. Min dan Max

A. Price

- Min = 3.00
- Max = 259.090000

B. Available

- Min = 2
- Max = 842

C. Sold

- Min = 1
- Max = 54052.000000

kesimpulan: nilai sold maksimum yang sangat besar yaitu 54.052 unit, perlu diperhatikan karena kemungkinan merupakan produk yang sangat populer atau adanya perbedaan jumlah penjualan antar produk. rentang harga parfum dari 3 hingga 259 masih tergolong wajar untuk pasar parfum online.

4. Standar Deviasi (std) - Variabilitas Data

A. Price

- Mean = 46.481200
- Std = 35.527862

B. Sold

- Mean = 766.266600
- Std = 3200.971733

Kesimpulan:pada kolom price, standar deviasi yang cukup besar menunjukkan variasi harga parfum cukup beragam dari murah hingga premium. pada kolom sold, nilai standar deviasi yang jauh lebih tinggi dari mean menandakan tingkat penjualan antar produk sangat tidak stabil, dengan sebagian kecil produk mendominasi penjualan.


2.2.1.3 Verifikasi Kualitas Data

2.2.1.3.1 Data Type Check

Data type check adalah proses pemeriksaan yang dilakukan untuk memastikan bahwa data yang dimasukkan ke dalam sistem atau database memiliki tipe data yang sesuai dengan yang telah ditentukan, seperti angka (integer), teks (string), atau tanggal (date). proses ini bertujuan untuk menjaga keakuratan dan konsistensi data, sehingga jika data yang dimasukkan tidak sesuai dengan tipe yang ditetapkan, sistem dapat menolak atau menandai data tersebut sebagai tidak valid.

```
df.dtypes
```

Perintah *df.dtypes* digunakan untuk menampilkan tipe data dari setiap kolom yang terdapat dalam DataFrame. Perintah ini membantu pengguna mengetahui jenis data yang dimiliki setiap variabel, seperti integer, float, atau object (teks), sehingga memudahkan dalam menentukan metode pengolahan dan analisis data yang tepat.



	0
brand	object
title	object
type	object
price	float64
priceWithCurrency	object
available	float64
availableText	object
sold	float64
lastUpdated	object
itemLocation	object
dtype:	object

Gambar 4 Perintah *df.dtypes*

Dapat dilihat pada baris kolom di atas, banyak kolom yang memiliki tipe data object karena berisi teks seperti id, nama pelanggan, kategori, dan lokasi. kolom sales dan profit sudah sesuai karena menggunakan tipe data float64 untuk nilai numerik, serta kolom quantity menggunakan int64 untuk jumlah produk. Tetapi di kolom lastUpdate seharusnya menggunakan date agar bisa lebih sesuai dengan tanggal, bulan, dan waktu.

2.2.1.3.2 Inconsistent Values

Inconsistent values adalah kondisi ketika terdapat perbedaan penulisan atau format data pada nilai yang seharusnya sama dalam suatu kolom, misalnya perbedaan huruf besar-kecil, ejaan yang berbeda, atau adanya spasi tambahan. Hal ini dapat menyebabkan data yang sebenarnya sama dianggap berbeda oleh sistem sehingga perlu diperiksa dan diperbaiki. Berikut adalah penerapan pencarian Inconsistent values pada data:

1. Brand

```
print(df['brand'].unique())
```

Perintah *print(df['brand'].unique())* digunakan untuk semua nilai unik yang

```
print(df['brand'].unique())

['Dior' 'AS SHOW' 'Unbranded' 'Giorgio Armani' 'Lattafa' 'Multiple Brands'
'Maison Alhambra' 'Gucci' 'Ralph Lauren' 'Dolce&Gabbana' 'SECERTMU'
'As Show' 'Versace' 'Paco Rabanne' 'Grandeur' 'Armaf' 'Carolina Herrera'
'Dolce & Gabbana' 'Clinique' 'Dumont' 'Afnan' 'Azzaro' 'Penhaligon's'
'Bharara' 'Valentino' 'Guy Laroche' 'Montblanc' 'Rasasi' 'Calvin Klein'
'UOMO' 'Givenchy' 'Polo Ralph Lauren' 'C.K.' 'John Varvatos' 'Nautica'
'As Picture Show' 'Kenneth Cole' 'Tommy Hilfiger' '2nd To None'
'Yves Saint Laurent' 'Cologne' 'AS SHOWN' 'Roja' 'MetaHerbal Labs'
'Mirage Brands' 'Abercrombie & Fitch' 'Moschino' 'As Shown'
'~ DOLCE & GABBANA ~' 'As picture show' 'Superz Budapest'
'Gianni Versace' 'Christian Dior' 'HERMES' 'Diesel' 'Lacoste' 'Dossier'
'Burberry' 'Michael Malul' 'Zara' 'Aramis' 'Jean Paul Gaultier'
'Davidoff' 'As Picture Shown' 'Bvlgari' 'Parfums de Marly'
'Salvatore Ferragamo' 'MontBlanc' 'Ard Al Zaafaran' 'Karl Lagerfeld'
'J. Del Pozo' 'Sean John' 'AS PICTURE SHOWN' 'YSL' 'Jaguar' 'EBC'
'Bath & Body Works' 'Issey Miyake' 'King' 'Prada' 'HUGO BOSS'
'Mont Blanc' 'BHARARA' 'Tommy Bahama' 'Paul Sebastian' 'Halloween'
'Boucheron' 'Thierry Mugler' 'Jo Malone' 'ISSEY MIYAKE' 'Khadlaj'
'Louis Vuitton' 'Creed' 'MFK' 'Hermes' 'fragrance' 'CHANEL' 'Lalique'
'Liz Claiborne' 'By Al Hambra' 'Joop' 'As shown' 'Ted Lapidus' 'AXE'
'as showed' 'Lomani' 'king of kings' 'rue21' 'Roja Dove' 'Tom Ford'
'Al Wataniah' 'MACARENA' 'Bentley' 'Coach' 'Coty' 'Lanvin'
'Claude Marsal' 'NIKOS' 'Lucianno' 'Viktor & Rolf' 'Rochas' 'PRADA'
```

Gambar 5 Perintah *print(df['brand'].unique())*

terdapat pada kolom brand dalam dataset. Perintah ini membantu mengetahui daftar merek yang tersedia pada data serta melihat apakah terdapat nilai yang tidak konsisten.

Berdasarkan hasil pengecekan pada kolom brand, terlihat adanya inkonsistensi penulisan nama brand akibat perbedaan penggunaan huruf kapital, variasi penamaan, serta adanya kesalahan penulisan. contohnya seperti dolce & gabbana, mont blanc, dan yves saint laurent yang muncul dengan bentuk berbeda seperti huruf besar semua, huruf kecil, dan penambahan simbol tertentu. selain itu, terdapat juga beberapa nilai yang bukan merupakan nama brand, seperti as shown atau does not apply. perbedaan ini

menyebabkan merek yang sama terbaca sebagai data yang berbeda dan masih terdapat data anomali, sehingga perlu dilakukan standarisasi penulisan dan perbaikan data agar data menjadi lebih rapi serta hasil analisis lebih akurat.

2. Title

```
print(df['title'].unique())
```

Perintah `print(df['title'].unique())` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom title dalam dataset. Perintah ini membantu mengetahui daftar judul produk yang tersedia pada data serta melihat apakah terdapat nilai yang tidak konsisten.

```
print(df['title'].unique())
```

```
["Christian Dior Sauvage Men's EDP 3.4 oz Fragrance Spray"  
'A-v-entus Eau de Parfum 3.3 oz 100ML Millesime EDP Col-ogne for Men New In Box'  
'HOGO BOSS cologne For Men 3.4 oz'  
"Acqua Di Gio by Giorgio Armani 6.7 Fl oz Eau De Toilette Spray Men' New & Sealed"  
'Lattafa Men's Hayaati Al Maleky EDP Spray 3.4 oz Fragrances 6291108734056"  
'Men's Perfume Sampler 10pcs Sample Vials Designer Fragrance Samples for Men'  
'Glacier Bold by Maison Alhambra 3.4oz EDP for Men NEW SEALED CAN'  
'Parfums De-Marly-Haltane Eau de Parfum spray 4.2 oz for Men New in Box'  
'Hawas for him Eau De Parfum By Rasasi 100ml 3.4 FL OZ NEW'  
'Gucci Guilty for Him - Classic 3oz Eau de Toilette Spray, Brand New'  
'Polo Blue by Ralph Lauren 4.2 oz EDT Cologne for Men Brand New In Box'  
'Dolce & Gabbana Light Blue Men 4.2 oz / 125 mL EDT Spray Brand New & Sealed'  
'New 2024 Sexy Cologne Cupid Hypnosis Long Lasting Pheromone Perfume for Men'  
'Sauvage Eau de Parfum Spray For Men 3.4 Oz/100ml New In Seald Box'  
'Eau Fraiche By Versace 3.4 oz 100 ml Eau de Toilette Brand New Sealed In Box'  
"1 Million by Paco Rabanne 3.4 Fl oz / 100 ml PARFUM Spray Men's New & Sealed"
```

Gambar 6 print(df['title'].unique())

Berdasarkan hasil pengecekan pada kolom Title, terlihat adanya inkonsistensi penulisan nama brand akibat perbedaan penggunaan huruf kapital, variasi penamaan serta penulisan yang salah. Misalnya dior sauvage muncul sebagai sauvage eau de parfum, dior sauvage edp, sauvage for men, hingga penulisan yang salah seperti savage. selain itu terdapat juga perbedaan penggunaan huruf besar dan simbol pada nama produk. perbedaan ini menyebabkan title yang sama terbaca sebagai data yang berbeda, sehingga perlu dilakukan standarisasi penulisan dan perbaikan data agar data menjadi lebih rapi dan hasil analisis lebih akurat.

3. Type

```
print(df['type'].unique())
```

Perintah `print(df['type'].unique())` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom `type` dalam dataset. Perintah ini membantu mengetahui daftar jenis produk yang tersedia pada data serta melihat apakah terdapat nilai yang tidak konsisten pada kolom tersebut.

```
print(df['type'].unique())
```

```
['Eau de Parfum' 'Eau de Toilette' 'Fragrances' 'Perfume' '/' 'PARFUM'
 'Parfum' 'Concentrated Uncut Pure Body Oil' 'LE PARFUM' 'Eau De Parfum'
 nan 'Unscented' 'Eau de Cologne' '~ THE ONE EAU DE PARFUM SPRAY ~'
 'EXTRAIT DE PARFUM' 'Eau De Toilette' 'Eau De Parfum Intense' 'Pheromone'
 'Aftershave' 'Fragrance & Perfume' 'Eau de Perfume'
 'Jo Malone Cologne Intense Spray' 'Y' 'Gift Sets'
 'Fragrance Rolling Ball' 'Body Spray' 'Eau de toilette'
 'Eau de Toilette'
 'Eau De Toilette, Eau De Parfum, Eau De Parfum Intense' 'Cologne'
 'le parfum' 'Eau de Toilette Intense'
 'Eau de Cologne Spray, Cologne Spray' 'Extrait De Parfum' 'Fine Cologne'
 'Does not apply' 'EDT' 'Extrait de Parfum' 'Editions Parfums'
 'DIOR HOMME COLOGNE' 'Deodorant' 'De Nuit'
 'Eau de Toilette, Cologne Spray' 'Parfum Intense' 'Eau de Parfum Intense'
 'cologne' 'EAU DE COLOGNE SPRAY' 'Roll On' 'Elixir de Parfum' 'Elixir'
 'Various' 'Assorted' 'Fragrance Oil' 'Eau de Parfum/ Eau de Toilette'
 'Deodorant Body Spray' 'Oil' 'Splash-on' 'edt' 'EDC' 'Car Air Freshener'
 'Eau De Cologne' 'Fragrance Body Spray' 'Body Oil' 'Cologne spray']
```

Gambar 7 perintah `print(df['type'].unique())`

Berdasarkan hasil pengecekan pada kolom `type`, terlihat adanya inkonsistensi penulisan `type` produk akibat perbedaan penggunaan huruf kapital, variasi penamaan, serta kesalahan penulisan. misalnya `eau de parfum` ditulis dalam berbagai bentuk seperti `Eau de Parfum`, `Eau De Parfum`, `EAU DE PARFUM`, `parfum`, `le parfum`, hingga bentuk lain seperti `EDP`. hal serupa juga terjadi pada `eau de toilette` yang muncul sebagai `Eau de Toilette`, `eau de toilette`, `EDT`, dan `Eau de Toillette`. selain itu terdapat data yang bukan kategori konsentrasi parfum, seperti `gift sets`, `deodorant`, `body spray`, `car air freshener`, `assorted`, `various`, serta nilai umum seperti `does not apply`. perbedaan ini menyebabkan `type` yang seharusnya sama terbaca sebagai data yang berbeda, sehingga perlu dilakukan standarisasi penulisan dan perbaikan data agar data menjadi lebih rapi serta hasil analisis lebih akurat.

4. Price

```
print(df['price'].unique())
```

Perintah `print(df['price'].unique())` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom price dalam dataset. Perintah ini membantu mengetahui daftar harga produk yang tersedia pada data serta melihat apakah terdapat nilai yang tidak konsisten pada kolom tersebut.

```

▶ print(df['price'].unique())

... [ 84.99 109.99 100.    44.99 16.91 14.99 30.99 85.    15.89 49.99
      34.99 29.95 15.99 59.99 68.99 37.99 29.99 39.99 83.95 29.94
      21.99 33.7  35.99 89.97 92.99 87.99 119.99 99.99 51.91 32.85
      16.98 32.89 45.11 19.73 40.6  54.99 40.99 34.84 34.72 46.33
      39.    21.54 32.97 23.34 28.75 27.94 32.5  45.95 69.99 13.99
      36.88 24.7  26.11 6.65  25.99 60.99 47.88 31.08 24.43 38.57
      24.45 16.26 22.5  15.03 8.32  37.8  23.56 27.59 26.5  35.71
      23.89 10.99 70.99 16.99 126.99 159.99 39.95 13.66 89.99 92.56
      13.86 17.99 79.99 33.95 24.5  49.96 26.97 30.    189.99 125.
      28.91 25.43 11.    161.99 58.99 48.99 17.    65.97 36.68 20.
      77.07 64.99 36.99 37.5  21.01 6.97  65.68 51.99 28.99 34.98
      25.49 41.99 27.3  48.    45.68 82.99 11.99 32.99 17.85 38.24
      125.99 36.36 33.45 44.    15.4  13.5  52.62 50.08 28.95 12.2
      28.93 54.92 25.98 74.8  39.77 86.87 44.94 18.99 17.95 36.81
      15.    53.99 22.98 22.24 28.5  29.    17.12 30.07 63.99 38.99
      54.91 124.96 54.86 35.68 21.95 63.69 259.09 31.99 28.79 46.99
      8.84  94.99 70.66 52.99 129.    202.95 57.46 45.49 55.    27.03
      45.69 12.98 25.7  45.99 47.99 32.    38.53 13.89 28.65 69.02
      22.99 18.1  57.17 9.61 138.99 44.49 23.49 29.19 16.39 7.96

```

Gambar 8 `print(df['price'].unique())`

Berdasarkan hasil pengecekan pada kolom price, terlihat bahwa data sudah berbentuk numerik dan memiliki banyak variasi nilai. harga produk berkisar mulai dari sekitar 3.00 hingga lebih dari 250.00, yang menunjukkan adanya perbedaan kelas produk, mulai dari parfum harga rendah hingga parfum premium. variasi harga yang besar ini merupakan kondisi yang wajar karena hal ini dipengaruhi oleh faktor merek, ukuran produk, konsentrasi parfum, serta edisi khusus. Tetapi, perlu dilakukan analisis lebih lanjut untuk memastikan tidak terdapat kesalahan input data serta agar hasil analisis harga menjadi lebih akurat.

5. PriceWithCurrency

```
print(df['PriceWithCurrency'].unique())
```

Perintah `print(df['PriceWithCurrency'].unique())` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom PriceWithCurrency dalam dataset. Perintah ini membantu mengetahui daftar harga yang tersedia pada data serta melihat apakah terdapat nilai yang tidak konsisten pada kolom tersebut.

```
print(df['priceWithCurrency'].unique())
```

```
[ 'US $84.99/ea' 'US $109.99' 'US $100.00' 'US $44.99/ea' 'US $16.91'
  'US $14.99' 'US $30.99/ea' 'US $85.00' 'US $15.89' 'US $49.99/ea'
  'US $34.99/ea' 'US $29.95/ea' 'US $15.99' 'US $59.99/ea' 'US $68.99/ea'
  'US $37.99' 'US $29.99/ea' 'US $39.99/ea' 'US $83.95' 'US $29.94/ea'
  'US $21.99/ea' 'US $49.99' 'US $33.70' 'US $35.99' 'US $89.97/ea'
  'US $92.99' 'US $87.99' 'US $119.99' 'US $99.99' 'US $51.91/ea'
  'US $32.85/ea' 'US $16.98/ea' 'US $32.89/ea' 'US $45.11' 'US $19.73'
  'US $40.60/ea' 'US $54.99' 'US $40.99' 'US $34.84/ea' 'US $34.72/ea'
  'US $46.33/ea' 'US $39.00' 'US $21.54/ea' 'US $32.97/ea' 'US $23.34/ea'
  'US $28.75' 'US $27.94/ea' 'US $32.50' 'US $45.95' 'US $69.99'
  'US $13.99' 'US $36.88/ea' 'US $24.70/ea' 'US $26.11/ea' 'US $6.65'
  'US $25.99/ea' 'US $60.99/ea' 'US $47.88/ea' 'US $31.08/ea' 'US $24.43'
  'US $35.99/ea' 'US $25.99' 'US $38.57/ea' 'US $24.45/ea' 'US $16.26/ea'
  'US $22.50' 'US $15.03' 'US $8.32/ea' 'US $37.80/ea' 'US $23.56/ea'
  'US $27.59/ea' 'US $26.50' 'US $35.71' 'US $23.89/ea' 'US $10.99/ea'
  'US $70.99/ea' 'US $16.99' 'US $126.99' 'US $159.99/ea' 'US $39.95'
  'US $13.66' 'US $54.99/ea' 'US $89.99' 'US $109.99/ea' 'US $92.56/ea' ]
```

Gambar 9 print(df['pricewithcuerency'].unique())

Berdasarkan hasil pengecekan pada kolom PriceWithCurrency, terlihat bahwa sebagian besar harga parfum sekitar 20\$–80\$, yang menunjukkan mayoritas produk dijual pada harga yang masih terjangkau oleh konsumen. Namun, terdapat beberapa harga yang jauh lebih tinggi dibandingkan harga lainnya, bahkan mencapai di atas 150\$ hingga lebih dari 200\$, sehingga mengindikasikan adanya produk kategori premium atau edisi khusus. berdasarkan hasil pengecekan pada kolom secara keseluruhan, variasi harga ini masih wajar, tetapi perlu dilakukan pemeriksaan kembali untuk memastikan tidak terjadi kesalahan input data.

6. Available

```
print(df['available'].unique())
```

Perintah `print(df['available'].unique())` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom available dalam dataset. Perintah ini membantu mengetahui status ketersediaan produk pada data serta melihat apakah terdapat nilai yang tidak konsisten pada kolom tersebut. status ketersediaan produk pada data serta melihat apakah terdapat nilai yang tidak konsisten pada kolom tersebut.

```
print(df['available'].unique())
```

```
[ 10.  8.  2. nan  9.  7.  5.  4.  3. 620. 383. 71. 96. 756.
 452. 161. 56.  6. 842. 484. 12. 322. 323. 33. 48. 116. 272. 226.
 127. 224. 44. 124. 207. 310. 199. 101. 84. 31. 13. 487. 138. 66.
  95. 155. 40. 52. 23. 36. 50. 72. 49. 24. 92. 82. 62. 202.
 311. 16. 20. 129. 15. 22. 73. 51. 74. 60. 113. 93. 83. 102.
 150. 47. 59. 53. 86. 26. 28. 39. 19. 57. 37. 54. 21. 65.
 68. 110. 29. 130. 88. 45.]
```

Gambar 10 print(df['Avaiblable'].unique()) untuk pricewithcurrency

Berdasarkan hasil pengecekan pada kolom Available, terlihat bahwa sebagian besar nilai berada pada rentang kecil hingga menengah sekitar 2–150, yang menunjukkan kebanyakan produk memiliki jumlah penjualan atau stok yang normal. Namun, terdapat beberapa nilai yang sangat tinggi seperti di atas 300 hingga 800, yang mengindikasikan adanya produk dengan performa penjualan yang lebih besar dibandingkan yang lain atau kemungkinan perbedaan jenis data.

7. AvailableText

```
print(df['availableText'].unique())
```

Perintah `print(df['availableText'].unique())` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom availableText dalam dataset. Perintah ini membantu mengetahui informasi teks mengenai ketersediaan produk pada data serta melihat apakah terdapat nilai yang tidak konsisten pada kolom tersebut.

```
print(df['availableText'].unique())

['More than 10 available / 116 sold' '8 available / 48 sold'
'More than 10 available / 27 sold' '2 available / 159 sold'
'Limited quantity available / 156 sold'
'More than 10 available / 79 sold' '9 available / 39 sold'
'Last One / 6 sold' '10 available / 17 sold' '8 available / 68 sold'
'More than 10 available / 615 sold' '7 available / 458 sold'
'More than 10 available / 889 sold' '9 available / 63 sold'
'7 available / 136 sold' '2 available / 20 sold'
'More than 10 available / 44 sold' '5 available / 384 sold'
'More than 10 available / 236 sold' '4 available / 22 sold'
'Limited quantity available / 9,208 sold' '4 available / 86 sold'
'3 available / 187 sold' 'More than 10 available / 131 sold'
'2 available / 43 sold' '10 available / 920 sold' '5 available / 19 sold'
'2 available / 4 sold' '10 available / 34 sold' 'Last One / 30 sold'
'4 available / 47 sold' '8 available / 170 sold'
'More than 10 available / 8,385 sold' '10 available / 295 sold'
'620 available / 2,345 sold' '383 available / 5,032 sold'
'Limited quantity available / 258 sold'
'Limited quantity available / 55 sold' '8 available / 276 sold'
'Limited quantity available / 5,582 sold' 'Last One / 8 sold'
'More than 10 available / 37 sold']
```

Gambar 9 `print(df['availableText'].unique())`

Berdasarkan kolom availableText, terlihat bahwa sebagian besar nilai berada pada kisaran rendah hingga menengah, namun terdapat banyak nilai yang sangat besar hingga puluhan ribu. Hal ini menunjukkan adanya perbedaan jumlah data yang cukup jauh antar data. Tetapi sebaiknya dilakukan pemeriksaan kembali untuk memastikan bahwa semua data telah sesuai sehingga nantinya dapat memudahkan dalam proses analisis.

8. Sold

```
print(df['sold'].unique())
```

Perintah `print(df['sold'].unique())` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom sold dalam dataset. Perintah ini membantu mengetahui variasi jumlah produk yang terjual pada data serta melihat apakah terdapat nilai yang tidak konsisten pada kolom tersebut.

```
▶ print(df['sold'].unique())
... 5.5200e+02 7.8000e+02 3.5800e+02 8.7000e+01 2.3000e+01 2.2930e+03
1.4000e+01 4.2000e+01 1.1460e+03 3.2400e+02 3.1600e+02 1.5700e+02
7.3000e+01 4.5000e+01 4.6400e+02 2.2500e+02 4.2400e+02 2.7000e+02
2.8000e+01 1.6900e+02 8.4900e+02 1.9250e+03 7.0200e+02 1.2900e+02
1.6000e+01 1.0100e+02 1.4700e+02 9.0000e+00 1.6500e+02 2.3500e+02
2.7500e+02 9.8000e+01 1.8000e+01 2.4860e+03 8.0300e+02 1.1000e+01
5.0000e+00 6.4000e+01 3.8000e+01 7.0000e+00 1.6000e+02 4.5200e+03
nan 1.0000e+01 1.1100e+02 7.6000e+01 4.1000e+02 2.9000e+01
8.2500e+02 8.1000e+01 1.3549e+04 8.6600e+02 4.7100e+02 1.5000e+01
7.7100e+02 9.1600e+02 1.3910e+03 3.9420e+03 1.1400e+03 5.0980e+03
1.8200e+02 4.7640e+03 2.4650e+03 1.5360e+03 4.3000e+02 3.1718e+04
3.2200e+02 1.0440e+03 2.0400e+02 2.1310e+04 7.5000e+01 1.4840e+03
2.5700e+02 1.2340e+03 1.2000e+01 2.4300e+02 5.1200e+02 1.4240e+03
5.6600e+02 5.7000e+01 5.9700e+02 6.1000e+01 4.0000e+01 2.3300e+02
2.2060e+03 1.5100e+02 6.5000e+01 4.4800e+02 5.8800e+02 4.7330e+03
4.5600e+02 1.3000e+01 5.6000e+01 9.4100e+03 1.0240e+03 5.8100e+02
```

Gambar 10 `print(df['sold'].unique())`

Berdasarkan kolom sold, terlihat bahwa sebaran nilai penjualan sangat bervariasi, dimana sebagian besar berada pada rentang puluhan hingga ratusan, namun terdapat beberapa nilai yang jauh lebih besar seperti 9.208, 30.655, 54.052, hingga 40.130. Sebaiknya dilakukan pemeriksaan kembali dan sebuah penanganan untuk memastikan bahwa semua nya telah sesuai sehingga nantinya dapat memudahkan dalam proses analisis.

9. LastUpdate

```
print(df['lastUpdated'].unique())
```

Perintah `print(df['lastUpdated'].unique())` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom lastUpdated dalam dataset. Perintah ini membantu mengetahui variasi waktu atau tanggal pembaruan data serta melihat apakah terdapat nilai yang tidak konsisten pada kolom tersebut

```
print(df['lastUpdated'].unique())
```

```
'May 21, 2024 19:32:52 PDT' 'May 24, 2024 08:50:11 PDT'
'Mar 06, 2024 12:02:36 PST' 'May 23, 2024 14:34:55 PDT'
'May 12, 2024 09:22:09 PDT' 'May 24, 2024 10:21:23 PDT'
'May 21, 2024 19:21:40 PDT' 'May 23, 2024 08:01:21 PDT'
'May 07, 2024 07:48:23 PDT' 'May 24, 2024 08:56:44 PDT'
'May 24, 2024 07:22:11 PDT' 'May 17, 2024 19:44:33 PDT'
'May 23, 2024 03:00:09 PDT' 'May 21, 2024 22:39:17 PDT'
'May 24, 2024 08:16:13 PDT' 'May 16, 2024 08:36:58 PDT'
'May 21, 2024 01:44:29 PDT' 'May 23, 2024 01:40:32 PDT'
'May 21, 2024 23:36:30 PDT' 'Feb 28, 2024 07:26:54 PST'
'May 23, 2024 21:56:47 PDT' 'May 22, 2024 19:01:37 PDT'
'May 16, 2024 15:22:05 PDT' 'May 13, 2024 05:49:38 PDT'
'May 13, 2024 09:33:41 PDT' 'Apr 22, 2024 05:34:36 PDT'
'May 18, 2024 15:52:35 PDT' 'May 23, 2024 05:20:25 PDT'
'May 23, 2024 12:09:40 PDT' 'May 17, 2024 12:17:44 PDT'
'May 23, 2024 02:11:39 PDT' 'May 09, 2024 22:38:22 PDT'
'Sep 15, 2023 06:32:59 PDT' 'May 23, 2024 23:20:00 PDT'
'Feb 26, 2024 12:33:18 PST' 'Apr 17, 2024 23:41:54 PDT'
'May 15, 2024 17:42:12 PDT' 'May 23, 2024 16:11:19 PDT'
'May 24, 2024 07:13:32 PDT' 'May 24, 2024 08:53:14 PDT'
'May 16, 2024 09:13:11 PDT' 'May 20, 2024 19:16:37 PDT'
'May 23, 2024 08:08:50 PDT' 'May 20, 2024 11:56:38 PDT'
'May 19, 2024 17:29:51 PDT' 'May 14, 2024 15:34:41 PDT'
```

Gambar 11 `print(df['lastUpdated'].unique())`

.Berdasarkan hasil pengecekan pada kolom lastupdated, format penulisan tanggal, bulan, dan tahun sudah terlihat baik serta konsisten karena seluruh data menggunakan format yang sama.

10. Item Location

```
print(df['itemLocation'].unique())
```

Perintah `print(df['itemLocation'].unique())` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom itemLocation dalam dataset. Perintah ini membantu mengetahui daftar lokasi produk yang tersedia pada data serta melihat apakah terdapat nilai yang tidak konsisten pada kolom tersebut.

```
print(df['itemLocation'].unique())
```

```
... 'Allen Park, Michigan, United States' 'Atlanta, Georgia, Canada'
'Dearborn, Michigan, United States'
'Reinholds, Pennsylvania, United States'
'Brooklyn, New York, United States' 'Houston, Texas, United States'
'Englewood Cliffs, New Jersey, United States'
'Ithaca, New York, United States' 'shanghai, China'
'Dearborn Heights, Michigan, United States'
'Ecorse, Michigan, United States' 'Warren, Michigan, United States'
'San Francisco, California, United States' 'Dayton, New Jersey, Hong Kong'
'San Jose, California, United States' 'Miami, Florida, United States'
'Hamtramck, Michigan, United States' 'Flat Lick, Kentucky, United States'
'Elmhurst, New York, United States'
'Hackensack, New Jersey, United States' 'Dallas, Texas, United States'
'Pomona, California, United States' 'Katy, Texas, United States'
'College Point, New York, United States' 'NEW YORK, United States'
'New York, USA, Hong Kong' 'Brenham, Texas, United States'
'Richmond Hill, New York, United States'
'Dexter, Michigan, United States' 'Phoenix, Arizona, United States'
'Peekskill, New York, United States' 'Edison, New Jersey, United States'
'Armada, Michigan, United States' 'Kalamazoo, Michigan, United States'
```

Gambar 12 `print(df['itemLocation'].unique())`


Berdasarkan kolom location, terlihat adanya ketidakkonsistenan penulisan data lokasi, dimana format yang digunakan tidak sama, mulai dari penulisan lengkap hingga hanya negara atau kode wilayah saja. Selain itu, ada perbedaan penggunaan huruf kapital dan variasi penulisan nama lokasi yang sama seperti Hong Kong, HongKong, dan HK, serta beberapa data yang kurang jelas seperti adanya kode wilayah. Hal ini menyebabkan lokasi yang sebenarnya sama terbaca sebagai data yang berbeda, sehingga perlu dilakukan standarisasi penulisan agar data lebih rapi dan hasil analisis menjadi lebih akurat.

2.2.1.3.3 Missing Values

Missing values adalah kondisi ketika terdapat data yang kosong atau tidak terisi pada suatu kolom dalam dataset. Hal ini dapat terjadi karena data tidak tersedia, kesalahan saat pengumpulan data, atau proses penyimpanan data yang tidak lengkap. Missing values perlu diidentifikasi dan ditangani karena dapat mempengaruhi hasil analisis dan mengurangi kualitas data. Penerapan Missing Values dapat dilakukan dengan perintah sebagai berikut:

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])
```

Perintah `pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])` digunakan untuk menghitung persentase missing values pada setiap kolom dalam dataset. Perintah `df.isna()` mendeteksi nilai yang kosong, kemudian `sum()` menghitung jumlah nilai kosong pada setiap kolom. Nilai tersebut dibagi dengan `len(df)` yaitu jumlah total baris data lalu dikalikan 100 untuk mendapatkan persentasenya. Hasilnya kemudian ditampilkan dalam bentuk DataFrame dengan nama kolom 'Null Ratio in %' sehingga memudahkan pengguna melihat persentase data yang hilang pada setiap kolom.



The screenshot shows a Jupyter Notebook interface. At the top, a code cell contains the command: `pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])`. Below the code cell, the output is displayed as a DataFrame with two columns: the column names and the 'Null Ratio in %'. The data is as follows:

	Null Ratio in %
brand	0.1
title	0.0
type	0.3
price	0.0
priceWithCurrency	0.0
available	11.1
availableText	0.3
sold	0.6
lastUpdated	5.3
itemLocation	0.0

Gambar 13 Missing Values

Berdasarkan hasil pengecekan missing values, masih terdapat beberapa kolom yang memiliki nilai kosong atau null, yaitu brand sebesar 0,1%, type 0,3%, available 11,1%, availableText 0,3%, sold bold text 0,6%, dan lastUpdated 5,3%. kondisi ini menunjukkan bahwa masih ada informasi terkait brand, tipe produk, jumlah penjualan, ketersediaan produk, serta waktu pembaruan data yang belum terisi. hal tersebut perlu diperhatikan karena berpotensi memengaruhi analisis stok dan aktivitas penjualan, sehingga diperlukan penanganan seperti perbaikan atau pembersihan data agar hasil analisis menjadi lebih akurat. sementara itu, kolom lainnya tergolong aman karena memiliki persentase nilai kosong yang sangat kecil bahkan mencapai 0%, sehingga tingkat kelengkapan datanya sudah baik.

2.2.1.3.4 Duplicated Values

Duplicated values adalah kondisi ketika terdapat data atau baris yang sama muncul lebih dari satu kali dalam dataset. Hal ini biasanya terjadi karena kesalahan saat pengumpulan atau penggabungan data. Data duplikat perlu diperiksa karena dapat mempengaruhi hasil analisis dan menyebabkan informasi menjadi tidak akurat. Penerapan duplicated values dapat dilakukan dengan perintah sebagai berikut:

```
df[df.duplicated()]
```

Perintah `df[df.duplicated()]` digunakan untuk menampilkan baris data yang duplikat dalam dataset. Fungsi `duplicated()` akan mendeteksi data yang memiliki nilai yang sama dengan baris sebelumnya pada semua kolom. Dengan menggunakan perintah ini, pengguna dapat mengetahui apakah terdapat data yang sama atau berulang dalam dataset sehingga dapat dipertimbangkan untuk dilakukan pembersihan data (data cleaning).

```
df[df.duplicated()]
```

```
brand title type price priceWithCurrency available availableText sold lastUpdated itemLocation
```

Gambar 14 Duplicated Values

Berdasarkan hasil pengecekan duplicated values, tidak ditemukan data yang terduplikasi pada dataset. hal ini menunjukkan bahwa setiap baris data sudah bersifat unik sehingga tidak terjadi pengulangan informasi, dan proses pembersihan data untuk duplikasi tidak perlu dilakukan.

2.2.1.3.5 Outliers Values

Outliers values adalah kondisi ketika terdapat nilai data yang sangat berbeda atau menyimpang jauh dari sebagian besar data lainnya dalam suatu dataset. Nilai ini dapat muncul karena kesalahan pencatatan data, variasi yang sangat tinggi, atau kondisi tertentu pada data. Outliers perlu diperiksa karena dapat mempengaruhi hasil analisis dan menyebabkan interpretasi data menjadi kurang akurat. Penerapan outliers values dapat dilakukan dengan perintah sebagai berikut:

```
results = []
cols = df.select_dtypes(include=['float64', 'int64'])
for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5*iqr
    upper_bound = q3 + 1.5*iqr
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers)/len(df))*100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})
results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
results_df = results_df.rename_axis(None, axis=0).rename_axis('Kolom', axis=1)
display(results_df)
```

Pada tahap ini, menggunakan perintah berupa membuat list *results* untuk menyimpan hasil perhitungan. Kemudian *df.select_dtypes(include=['float64', 'int64'])* digunakan untuk memilih kolom dengan tipe data numerik. Selanjutnya pada setiap kolom dihitung Q1 (kuartil 25%) dan Q3 (kuartil 75%), kemudian dihitung IQR = Q3 – Q1. Batas bawah dan batas atas outlier ditentukan dengan rumus $Q1 - 1.5 \times IQR$ dan $Q3 + 1.5 \times IQR$. Data yang berada di luar

Kolom	Persentase Outliers
price	5.4
available	10.1
sold	13.6

Gambar 15 Outliers Values

batas tersebut dianggap sebagai outliers. Setelah itu dihitung persentase outliers dengan membandingkan jumlah data outlier dengan total data. Hasil perhitungan kemudian disimpan dalam bentuk DataFrame yang berisi nama kolom dan persentase outliers, lalu ditampilkan menggunakan `display(results_df)` agar mudah dibaca.

Berdasarkan hasil deteksi outliers, terlihat bahwa ada kolom yang memiliki persentase nilai ekstrem. Yaitu kolom `sold` memiliki persentase nilai ekstrem sebesar 13,6%, kolom `available` sebesar 10,1% dan `price` sebesar 5,4%. Hal ini menunjukkan adanya perbedaan nilai yang cukup jauh pada sebagian data, terutama pada jumlah penjualan dan ketersediaan produk. kondisi tersebut dapat memengaruhi hasil analisis dan model yang akan kita bangun nantinya, sehingga perlu tindakan lebih lanjut.

2.2.2 Eksplorasi Data (EDA)

Dalam proses visualisasi dan analisis data, diperlukan penggunaan library Python untuk membantu menampilkan grafik atau visualisasi data. Library yang digunakan yaitu:

```
import seaborn as sns
import matplotlib.pyplot as plt
```


2.2.2.1 Comparison

Comparison merupakan proses membandingkan dua atau lebih data atau variabel untuk melihat perbedaan, persamaan, atau hubungan di antara data tersebut. Proses ini bertujuan untuk memperoleh informasi yang lebih jelas sehingga memudahkan dalam memahami pola atau kecenderungan yang terdapat dalam dataset. Penerapan comparison dapat dilakukan dengan menggunakan bar chart sebagai berikut:

```
penjualan_brand =
df.groupby('brand')['sold'].sum().sort_values(ascending=False).head(10)
plt.figure(figsize=(10,6))
sns.barplot(x=penjualan_brand.index,y=penjualan_brand.values,palette='viridis',hue=penj
ualan_brand.index,legend=False)
plt.title('10 Brand Teratas Berdasarkan Total Penjualan')
plt.xlabel('Brand Parfume')
plt.ylabel('Total Produk Terjual')
plt.xticks(rotation=45)
plt.show()
```

Untuk menerapkan comparison pada bar chart digunakan perintah `df.groupby('brand')['sold'].sum()` untuk mengelompokkan data berdasarkan brand lalu menjumlahkan seluruh nilai pada kolom sold untuk mengetahui total produk yang terjual dari setiap brand. Kemudian `sort_values(ascending=False).head(10)` berfungsi untuk mengurutkan data dari penjualan tertinggi ke terendah dan mengambil 10 brand teratas. Setelah itu dibuat visualisasi bar chart menggunakan matplotlib dan seaborn dengan `sns.barplot()` agar perbandingan penjualan antar brand lebih mudah dilihat. Sumbu x menampilkan nama brand parfum, sedangkan sumbu y menunjukkan total produk yang terjual. Judul, label sumbu, serta rotasi teks juga ditambahkan agar grafik lebih jelas dan mudah dibaca.

Perbandingan antara brand dan sold digunakan karena bertujuan untuk mengetahui brand parfum mana yang paling banyak terjual. Dengan membandingkan kedua variabel tersebut, kita dapat melihat performa penjualan setiap brand serta mengidentifikasi brand yang paling diminati oleh konsumen



Gambar 16 Visualisasi Comparison

Berdasarkan visualisasi 10 brand teratas, terlihat bahwa Calvin Klein dan Versace memiliki total penjualan paling tinggi dibandingkan brand lainnya. Selanjutnya, brand seperti Davidoff, Azzaro, dan Armaf berada pada kategori penjualan menengah, sementara beberapa brand lainnya menunjukkan total penjualan yang relatif lebih rendah. Visualisasi ini menunjukkan adanya perbedaan distribusi penjualan antar brand, di mana beberapa brand mendominasi pasar dibandingkan yang lain. Hal ini mengindikasikan bahwa terdapat variasi

performa penjualan antar brand yang dapat dipengaruhi oleh berbagai faktor seperti harga, ketersediaan produk, maupun preferensi konsumen.


2.2.2.2 Composition

Composition merupakan proses untuk melihat susunan atau proporsi bagian-bagian yang membentuk suatu keseluruhan data. Proses ini bertujuan untuk mengetahui kontribusi setiap kategori terhadap total data sehingga memudahkan dalam memahami distribusi dan komposisi yang terdapat dalam dataset. Penerapan composition dapat dilakukan dengan menggunakan pie chart seperti contoh di bawah ini:

```
sales_by_brand = df.groupby('type')['sold'].sum().sort_values(ascending=False)
sales_by_brand_top3 = sales_by_brand.head(3)
plt.figure(figsize=(10, 8))
sales_by_brand_top3.plot(
    kind='pie',
    autopct='%1.1f%%',
    startangle=140,
    colors=plt.cm.Paired.colors
)
plt.title('Proporsi 3 Type Teratas Berdasarkan Total Penjualan')
plt.ylabel("")
plt.axis('equal')
plt.show()
```

Perintah di atas digunakan untuk melihat proporsi total penjualan berdasarkan type produk dengan menggunakan pie chart sehingga dapat diketahui type mana yang memiliki kontribusi penjualan terbesar. Untuk menerapkannya digunakan perintah `df.groupby('type')['sold'].sum()` untuk mengelompokkan data berdasarkan *type* lalu menjumlahkan seluruh nilai pada kolom *sold* sehingga diperoleh total penjualan setiap *type*. Kemudian `sort_values(ascending=False)` digunakan untuk mengurutkan data dari penjualan tertinggi ke terendah dan `head(3)` untuk mengambil tiga *type* dengan penjualan tertinggi. Setelah itu dibuat visualisasi pie chart menggunakan *matplotlib* dengan `plot(kind='pie')` sehingga proporsi penjualan masing-masing *type* dapat terlihat dalam bentuk persentase. Judul grafik, ukuran gambar, serta pengaturan sudut dan label persentase juga ditambahkan agar visualisasi lebih jelas dan mudah dipahami.

Penggunaan variabel type dan sold pada kode tersebut bertujuan untuk melihat proporsi penjualan berdasarkan jenis produk. Kolom type digunakan sebagai kategori untuk mengelompokkan data karena menunjukkan jenis atau tipe produk yang dijual. Sementara itu, kolom sold digunakan sebagai nilai yang dihitung karena menunjukkan jumlah produk yang terjual.



Gambar 17 Visualisasi Composition

Berdasarkan diagram proporsi 3 tipe parfum teratas, terlihat bahwa tipe eau de toilette mendominasi penjualan dengan persentase sekitar 86,8%. Sementara itu, eau de parfum memiliki kontribusi sebesar 8,4% dan eau de cologne sebesar 4,8%. Visualisasi ini menunjukkan adanya perbedaan distribusi penjualan yang cukup signifikan antar tipe parfum, di mana eau de toilette memiliki kontribusi yang jauh lebih besar dibandingkan tipe lainnya. Hal ini mengindikasikan bahwa tipe tersebut memiliki performa penjualan yang paling tinggi dalam dataset.

2.2.2.3 Distribution

Distribution merupakan proses untuk melihat penyebaran atau distribusi nilai dalam suatu data. Proses ini bertujuan untuk mengetahui bagaimana data tersebar, seperti nilai yang paling sering muncul, rentang data, serta kecenderungan pola yang terdapat dalam dataset. Penerapan distribution dapat dilakukan dengan menggunakan histogram dan boxplot seperti contoh di bawah ini:


1. Histogram

```
plt.figure(figsize=(10, 6))
sns.histplot(df['sold'], bins=20, kde=True)

plt.title('Distribusi Jumlah Produk Terjual')
plt.xlabel('Jumlah Terjual (sold)')
plt.ylabel('Frekuensi')
plt.show()
```

Perintah di atas digunakan untuk menampilkan distribusi jumlah produk yang terjual pada kolom sold menggunakan histogram. Perintah `plt.figure(figsize=(10, 6))` berfungsi mengatur ukuran grafik agar lebih jelas. Kemudian `sns.histplot(df['sold'], bins=20, kde=True)` digunakan untuk membuat histogram dari data sold, di mana `bins=20` membagi data ke dalam 20 interval agar pola penyebaran data terlihat lebih jelas, sedangkan `kde=True` menambahkan garis density untuk menunjukkan kecenderungan distribusi data. Selanjutnya `plt.title()`, `plt.xlabel()`, dan `plt.ylabel()` digunakan untuk menambahkan judul serta label pada sumbu x dan y agar grafik mudah dipahami, sedangkan `plt.show()` berfungsi untuk menampilkan visualisasi grafik.

Pada Visualisasi ini digunakan kolom sold karena berisi informasi jumlah produk yang terjual, sehingga dapat menunjukkan bagaimana penyebaran data penjualan dalam dataset. Dengan menggunakan kolom ini, distribusi penjualan dapat dianalisis untuk melihat pola serta frekuensi jumlah produk yang terjual.



Gambar 18 Visualisasi Distribution 1

Berdasarkan grafik distribusi jumlah produk terjual, terlihat bahwa sebagian besar data berada pada nilai penjualan yang rendah, sementara hanya sedikit produk yang memiliki jumlah penjualan yang sangat tinggi. Pola ini menunjukkan bahwa distribusi data bersifat tidak simetris dan cenderung condong ke kanan (right-skewed).

Selain itu, terlihat adanya beberapa nilai yang jauh lebih tinggi dibandingkan mayoritas data, yang mengindikasikan kemungkinan adanya outlier. Nilai-nilai ekstrem ini dapat memengaruhi hasil analisis, terutama dalam perhitungan statistik seperti rata-rata.


Distribusi ini menunjukkan adanya variasi penjualan antar produk, di mana sebagian besar produk memiliki penjualan rendah, sementara hanya sebagian kecil produk yang memiliki penjualan sangat tinggi.

2. Boxplot

```
plt.figure(figsize=(8, 6))
sns.boxplot(y=df['sold'])
plt.title('Deteksi Outlier Jumlah Produk Terjual')
plt.ylabel('Jumlah Terjual (sold)')
plt.show()
```

Perintah di atas digunakan untuk mendeteksi adanya outlier pada jumlah produk yang terjual di kolom sold menggunakan boxplot. Perintah `plt.figure(figsize=(8, 6))` berfungsi untuk mengatur ukuran grafik agar tampilan visualisasi lebih jelas dan mudah dibaca. Kemudian `sns.boxplot(y=df['sold'])` digunakan untuk membuat boxplot berdasarkan data pada kolom sold, sehingga dapat memperlihatkan sebaran data, nilai tengah (median), rentang data, serta nilai-nilai yang menyimpang jauh dari data lainnya atau outlier. Selanjutnya `plt.title('Deteksi Outlier Jumlah Produk Terjual')` digunakan untuk memberikan judul pada grafik, sedangkan `plt.ylabel('Jumlah Terjual (sold)')` digunakan untuk memberi label pada sumbu y agar informasi pada grafik lebih mudah dipahami. Terakhir, `plt.show()` digunakan untuk menampilkan visualisasi boxplot.

Pada visualisasi ini digunakan kolom sold karena berisi informasi jumlah produk yang terjual, sehingga dapat membantu mendeteksi adanya nilai penjualan yang menyimpang atau outlier. Berdasarkan visualisasi boxplot, terlihat terdapat beberapa outlier pada kolom sold, di mana beberapa produk memiliki jumlah penjualan yang sangat tinggi dibandingkan produk lainnya. Hal ini menunjukkan bahwa distribusi data penjualan tidak merata.



Gambar 19 Visualisasi Distribution 2

Berdasarkan boxplot jumlah produk terjual, terlihat adanya beberapa nilai yang berada jauh di atas mayoritas data, yang mengindikasikan adanya outlier. Selain itu, rentang data yang cukup lebar menunjukkan adanya variasi penjualan antar produk. Temuan ini sejalan dengan histogram sebelumnya yang menunjukkan distribusi condong ke kanan, di mana terdapat sejumlah kecil produk dengan nilai penjualan yang sangat tinggi. Oleh karena itu, boxplot digunakan untuk memperjelas dan mengkonfirmasi adanya nilai ekstrem dalam dataset.

2.2.2.4 Relationship


Relationship merupakan proses untuk melihat hubungan atau keterkaitan antara dua atau lebih variabel dalam suatu data. Proses ini bertujuan untuk mengetahui apakah terdapat hubungan yang kuat, lemah, maupun tidak ada hubungan antar variabel dalam dataset. Penerapan relationship dapat dilakukan dengan menggunakan heatmap seperti contoh di bawah ini:

```
plt.figure(figsize=(8, 6))
sns.heatmap(
    df[['price', 'sold', 'available']].corr(),
    annot=True,
    cmap='viridis',
    fmt='.2f')
```

```
plt.title('Korelasi Antar Variabel Numerik')
plt.show()
```

Perintah di atas digunakan untuk menampilkan korelasi antar variabel numerik menggunakan heatmap. Perintah `plt.figure(figsize=(8, 6))` digunakan untuk mengatur ukuran grafik agar lebih jelas. Kemudian `df[['price', 'sold', 'available']].corr()` digunakan untuk menghitung nilai korelasi antara kolom price, sold, dan available. Hasil korelasi tersebut divisualisasikan dengan `sns.heatmap()`, di mana `annot=True` menampilkan nilai korelasi pada setiap sel, `cmap='viridis'` mengatur gradasi warna heatmap, dan `fmt='.2f'` membatasi tampilan angka menjadi dua desimal. Terakhir `plt.title()` menambahkan judul grafik dan `plt.show()` digunakan untuk menampilkan visualisasi heatmap.

Perbandingan antara price, sold, dan available dilakukan untuk mengetahui hubungan antara harga produk, jumlah produk yang terjual, dan ketersediaan stok. Dengan membandingkan ketiga variabel tersebut, dapat dilihat apakah harga mempengaruhi jumlah penjualan serta bagaimana pengaruh ketersediaan produk dengan tingkat penjualan dalam dataset.



Gambar 20 Visualisasi Relationship

Berdasarkan heatmap korelasi, hubungan antara price dengan sold $-0,08$ dan available $-0,10$ yang berarti memiliki hubungan yang sangat lemah, sehingga harga produk tidak terlalu memengaruhi jumlah penjualan maupun ketersediaan stok. sementara itu, sold dan available memiliki korelasi positif rendah $0,26$, yang menunjukkan bahwa produk dengan stok cenderung memiliki penjualan sedikit lebih tinggi, meskipun pengaruhnya tidak terlalu kuat. secara keseluruhan, tidak terdapat hubungan linear yang signifikan antar variabel pada dataset ini.

BAB III

PENUTUP

3.1 Kesimpulan

Berdasarkan hasil analisis data penjualan parfum pria pada marketplace eBay menggunakan pendekatan Exploratory Data Analysis (EDA), dapat disimpulkan bahwa dataset memiliki beberapa permasalahan data seperti missing values, inconsistent values, serta outliers pada beberapa kolom, terutama pada kolom sold, available, dan price. Namun, tidak ditemukan duplicated values pada dataset sehingga data tergolong cukup baik untuk digunakan dalam proses analisis setelah dilakukan pemeriksaan kualitas data. Proses Data Understanding dan EDA membantu memahami karakteristik data serta memastikan kualitas data sebelum dilakukan analisis lebih lanjut.

Hasil visualisasi comparison menunjukkan bahwa brand Calvin Klein dan Versace menjadi brand dengan total penjualan tertinggi dibandingkan brand lainnya. Selain itu, visualisasi composition memperlihatkan bahwa jenis parfum Eau de Toilette mendominasi total penjualan dibandingkan jenis parfum lainnya. Hal ini menunjukkan bahwa popularitas brand dan jenis parfum memiliki pengaruh terhadap minat beli konsumen. Sementara itu, visualisasi distribution menunjukkan bahwa distribusi jumlah produk terjual bersifat skewed right, yang berarti sebagian besar produk memiliki tingkat penjualan rendah dan hanya sebagian kecil produk yang memiliki penjualan sangat tinggi.

Pada visualisasi relationship menggunakan heatmap, hubungan antara price dengan sold maupun available tergolong sangat lemah, sedangkan hubungan antara sold dan available hanya menunjukkan korelasi positif rendah. Hal ini menunjukkan bahwa harga produk bukan menjadi faktor utama yang memengaruhi tingkat penjualan parfum pada dataset ini. Secara keseluruhan, penerapan Exploratory Data Analysis (EDA) mampu membantu memahami pola penjualan, distribusi data, serta hubungan antar variabel sehingga informasi yang dihasilkan dapat mendukung proses pengambilan keputusan berdasarkan data.

3.2 Saran

Berdasarkan hasil analisis yang telah dilakukan, beberapa saran yang dapat diberikan adalah sebagai berikut:

1. Penjual dapat memfokuskan pengelolaan stok dan strategi promosi pada brand dengan tingkat penjualan tinggi seperti Calvin Klein dan Versace karena brand tersebut menunjukkan performa penjualan yang lebih baik dibandingkan brand lainnya.
2. Produk dengan jenis Eau de Toilette dapat diprioritaskan karena memiliki kontribusi penjualan terbesar dibandingkan jenis parfum lainnya sehingga berpotensi memberikan keuntungan yang lebih tinggi.
3. Perlu dilakukan standarisasi penulisan data seperti brand, type, dan lokasi agar data lebih konsisten dan mudah dianalisis sehingga hasil analisis dapat menjadi lebih akurat.
4. Penanganan terhadap missing values dan outliers perlu dilakukan agar kualitas data menjadi lebih baik serta dapat meminimalkan kesalahan dalam proses analisis dan interpretasi data.
5. Pada tahap Data Preparation, disarankan untuk melakukan Construct Data dengan membentuk atau menambahkan atribut baru yang dapat membantu proses analisis, seperti kategori harga parfum, kategori tingkat penjualan, maupun pengelompokan jenis parfum.
6. Selain itu, disarankan juga melakukan Data Reduction untuk mengurangi data yang tidak relevan atau terlalu kompleks sehingga proses analisis menjadi lebih efisien dan visualisasi data dapat lebih mudah dipahami.
7. Untuk pengembangan analisis selanjutnya, dapat ditambahkan variabel lain seperti rating produk, ulasan pelanggan, ukuran parfum, maupun kategori harga agar hasil analisis dapat memberikan insight yang lebih mendalam terkait faktor-faktor yang memengaruhi tingkat penjualan parfum pada marketplace eBay.